

Prova de Recuperação - Introdução à Ciência de Dados

23 de março de 2026

Instruções de entrega: Os materiais da prova estão na pasta `prova_rec` do repositório dados, disponível em <https://github.com/franklinpedro>.

A entrega deve ser feita até **25 de março de 2026**, pelo e-mail `pedrofranklin@ufu.br`, com os seguintes arquivos:

- **Q1** — um arquivo de texto (`.txt`, `.doc`, etc.) com o desenvolvimento e os cálculos;
- **Q2** — um arquivo `.R` com o código (e os cálculos inseridos como comentários), acompanhado de um arquivo de texto contendo os gráficos, as matrizes de confusão e as interpretações solicitadas.

Questão 1

As duas partes dessa questão devem ser entregues em um arquivo `txt`.

Parte a) (5 pontos)

Abaixo é fornecido um código em R que cria um modelo de árvore de decisão para um problema de classificação de câncer de mama. Analise o código e aponte o erro existente, explicando por que isso é um erro do ponto de vista da modelagem.

```
library(rpart)
library(rpart.plot)
library(dplyr)

treino <- read.csv("treino_cancer.csv")
teste <- read.csv("teste_cancer.csv")
treino <- treino[sample(nrow(treino)),]
print(c(nrow(treino), nrow(teste)))
```

[1] 25 275

```
modelo <- rpart(diagnostico ~ ., data = treino, method = "class")
previsao <- predict(modelo, newdata = teste, type = "class")
acuracia <- mean(previsao == teste$diagnostico)
```

```
print(accuracia)
```

```
[1] 0.643
```

Parte b) (20 pontos)

A seguir, a diretriz de um certo hospital: “O objetivo primário de qualquer ferramenta de triagem para câncer de mama é garantir a segurança da paciente. Nesta fase inicial do diagnóstico, consideramos um erro crítico e de alto risco quando uma paciente com tumor maligno é incorretamente classificada como benigna (falso negativo), pois isso pode atrasar o tratamento necessário. Por outro lado, classificar como maligna uma lesão benigna (falso positivo) é considerado um erro de menor impacto. Embora cause ansiedade e exija exames de confirmação adicionais (por exemplo, biópsia), esse resultado é gerenciável no nosso fluxo assistencial e não impede que, ao final do processo, a paciente receba o diagnóstico correto.”

A Tabela 1 apresenta duas matrizes de confusão para um problema de detecção de câncer de mama, usando o mesmo conjunto de teste em dois modelos diferentes.

Tabela 1: Matrizes de confusão; as linhas são as previsões.

(a) Árvore de decisão			(b) KNN		
	Maligno	Benigno		Maligno	Benigno
Maligno	60	16	Maligno	55	11
Benigno	20	104	Benigno	25	109

A classe “Maligno” significa que o tumor é maligno e a classe “Benigno” significa que o tumor não é maligno. Com base nas matrizes de confusão e na diretriz acima, escolha qual modelo é mais adequado para detecção de câncer de mama e justifique de forma clara, destacando o impacto relativo de falsos negativos e falsos positivos.

Questão 2 — Modelagem e Avaliação (65 pts)

Risco materno, neste contexto, refere-se à probabilidade de uma gestante apresentar desfechos adversos durante a gestação, o parto ou o puerpério, em função de suas condições clínicas e sinais fisiológicos. Identificar precocemente gestantes de alto risco (*high risk*) permite direcionar acompanhamento mais intensivo e intervenções oportunas; já gestantes de baixo risco (*low risk*) tendem a demandar um seguimento clínico rotineiro.

Nesta questão, você trabalhará com um conjunto contendo as variáveis: **Age** (idade), **SystolicBP** (pressão arterial sistólica), **DiastolicBP** (pressão arterial diastólica), **BS** (glicemia), **BodyTemp** (temperatura corporal), **HeartRate** (frequência cardíaca) e **RiskLevel** (nível de risco). Na pasta indicada no início da prova há dois arquivos: **treino.txt** e **teste.txt**. Trate **RiskLevel** como variável resposta. Antes da modelagem, explore o conjunto de treino por meio de visualizações. Construa pelo menos três gráficos que ajudem a compreender o problema e inclua-os no arquivo de

texto, comentando o que cada um revela sobre a distribuição das variáveis e suas relações com o nível de risco.

(a) Ajuste um modelo **KNN**. Antes do ajuste, padronize as variáveis preditoras numéricas. Use validação cruzada para escolher o melhor valor de k e informe qual foi selecionado. Explique por que a padronização é necessária para o KNN e para o SVM, mas desnecessária para a árvore de decisão e a floresta aleatória. **(10 pts)**

(b) Ajuste uma **Árvore de Decisão**. Apresente a visualização da árvore gerada e interprete as duas primeiras divisões (*splits*): quais variáveis foram escolhidas e o que isso sugere sobre sua importância para a classificação? **(10 pts)**

(c) Ajuste uma **Floresta Aleatória com 500 árvores** e apresente o gráfico de importância das variáveis. Quais variáveis mais contribuíram para a classificação? Compare com as divisões observadas na árvore do item (b). **(10 pts)**

(d) Ajuste um **SVM com kernel radial**. **(5 pts)**

Para cada um dos quatro modelos, apresente a **matriz de confusão** sobre os dados de teste, adotando a convenção de linhas para predição e considerando *high risk* como classe positiva. Identifique VP, FP, VN e FN.

(e) A partir dos valores da matriz de confusão de cada modelo (**sem usar funções prontas**), calcule as seguintes métricas: **(15 pts)**

$$\text{Acurácia} = \frac{VP + VN}{VP + FP + VN + FN}$$

$$\text{Sensibilidade} = \frac{VP}{VP + FN} \quad \text{Especificidade} = \frac{VN}{VN + FP} \quad \text{Precisão} = \frac{VP}{VP + FP}$$

$$F_1 = 2 \cdot \frac{\text{Sensibilidade} \times \text{Precisão}}{\text{Sensibilidade} + \text{Precisão}}$$

Organize os resultados em uma **tabela comparativa** com os quatro modelos nas linhas e as cinco métricas nas colunas.

(f) Com base na tabela do item (e): **(15 pts)**

- A acurácia é sempre a métrica mais adequada para comparar modelos? Em que situações outras métricas seriam mais informativas?
- Neste contexto de triagem de risco materno, classificar erroneamente como *low risk* uma gestante de alto risco (falso negativo) é mais grave do que o erro oposto, pois pode privar a paciente de acompanhamento intensivo em momento crítico. Qual métrica deve ter maior peso na escolha do modelo? Qual dos quatro modelos você escolheria? Justifique com base nos valores calculados.